

令和元年度卒業研究論文

URL の情報指向型クラシフィケーション

2020 年 2 月 7 日 (金)

指導教員 井上一成 教授

明石工業高等専門学校

電気情報工学科

報告者 E1533 西 総一朗

目次

第 1 章 序論	1
1.1 TCP/IP の課題	1
1.2 情報指向ネットワーク	2
1.3 本研究の目的	3
第 2 章 方針	5
2.1 URL のクラシフィケーション	5
2.2 プログラム	5
2.3 データの前処理	6
2.4 ハッシュアルゴリズム	7
第 3 章 衝突数の検証結果	9
3.1 URL の分類手法を利用するとき	9
3.2 ハッシュと URL の分類手法を併用したとき	9
参考文献	11

第1章

序論

1.1 TCP/IP の課題

1983年から今日のインターネットと呼ばれているネットワークにおいて通信プロトコルTCP/IPがデファクトスタンダードとなった[1]。約20年前のインターネットのトラヒックや利用形態は現在とは大きく異なっている。1992年の全世界のインターネットトラフィックは1日あたり約100GBであったが、その10年後の2002年には1秒あたり100GBに増え、2017年には1秒あたり45,000GB以上に到達した。また利用形態も2017年においてはトラヒックの75%をビデオコンテンツが占めている。Ciscoによると全世界のインターネットトラヒックは2022年には150,700GB/秒となりその82%をビデオコンテンツが占めると予測されている[2]。

また、インターネットの使用目的も変遷している。当初はインターネットを高性能コンピュタあるいは高性能プリンタを利用するように、様々なリソースを遠隔から共有することが主な目的であった。現在は情報の共有、情報の取得といった情報のやり取りが中心となっている。それに伴って、通信形態も変化している。従来のTCP/IPはホスト中心のHost-to-Hostの通信形態であり、IPプロトコルは位置情報であるネットワークアドレスを用いてホストアドレスを指定するというロケーション・オリエンティッド^{*1}な通信であった。ところが、現在は情報をユーザに送るというインフォメーション・セントリック^{*2}な通信形態に変わりつつある。

このようにTCP/IPの通信形態と現在のインターネットに求められている通信形態との間の差が広がっている。情報の効率的な取得のためにP2P^{*3}やCDN^{*4}などの新しいプロトコルが提案された。しかし、これらはロケーション・セントリックなTCP/IPネットワーク上のプロトコルであるので本質的な解決ではない。本来、情報を取得するという行為に対して、ネットワークアドレスやホストアドレスなどを意識する必要はなく、もし近くにある通信機器が当該コンテンツ(情報)^{*5}を持っておりそこから情報を取得できるなら、それはより効率的であり将来の通信量増大にも対応できると考えられる。そこで、情報を効率的に取得するために情報指向ネットワーク:Information-Centric-Network(ICN)[3]というプロトコル体系が提案された[4]。

^{*1} Location-oriented: 地理的指向な

^{*2} Information-Centric: 情報指向な

^{*3} Peer to Peer: インターネットにおいて一般的に用いられるクライアント・サーバ型モデルでは、データを保持・提供するサーバとそれに対してデータを要求・アクセスするクライアントという2つの立場が固定されているのに対して、各ビアに対して対等にデータの提供及び要求・アクセスを行う自立分散型のネットワークモデル

^{*4} Content Delivery Network: 頻繁に使われるWebサイトがあると一つのノード(サーバ)だけでは耐えきれないのいくつかのノードにデータを分散しておき、各ユーザは分散したノードに接続して情報を取得するという方法

^{*5} 参考文献[3]では情報(Information)とコンテンツ(Contents)は同様の意味で用いられている。本稿でも同様の意味で用いる。

1.2 情報指向ネットワーク

情報指向ネットワーク (ICN) においてユーザはサーバの IP アドレスではなくコンテンツ名を指定してコンテンツ取得要求を行い、そのコンテンツ要求を受け取った近隣のルータやノードが当該コンテンツを保持していた場合、それらはユーザに対してそのコンテンツを直接転送するプロトコル体系である。ICN において情報を保持している者をパブリッシャ (Publisher)，情報の取得要求を出すものをサブスクリーバ (Subscriber) と呼ぶ。また ICN では各コンテンツ (情報) に対してコンテンツ名 (名前) が対応付けられている。

ICNへのアプローチとして様々な研究がなされているが、現在最も多くの研究者により研究されている Named Data Networking (NDN)[5] 及びその前身である Content Centric Networking (CCN)[6] を代表的な ICN アーキテクチャとして述べる。CCN アーキテクチャはパロアルト研究所^{*6}により研究されている ICN の先駆となった本格的なアーキテクチャである。また、US Future Internet Architecture プログラム^{*7}によって資金提供された NDN プロジェクトは、CCN アーキテクチャをさらに発展させたものである。

■コンテンツ名 NDNにおけるコンテンツ名の命名規則は階層構造になっており、現在のインターネットで流通している識別子である Uniform-Resource-Locator (URL) に似ている。たとえば、コンテンツ名は /aueb.gr/ai/main.html となる。ただし、コンテンツ名は必ずしも URL とは一致せず、最初のセクション^{*8}は DNS 名または IP アドレスなどの形式である必要もない。つまり NDN では、各セクションについての具体的な規格は定義されていない。またコンテンツ取得要求において、要求されたコンテンツ名のプレフィックスの名前を持つ情報と一致すると見なされる。たとえば、/aueb.gr/ai/main.html/_v1/_s1 は /aueb.gr/ai/main.html という名前のコンテンツと一致する。これは要求されたコンテンツの初版であり、コンテンツを分割したセグメントの最初のデータを表している。このデータを受信したあとに Subscriber は /aueb.gr/ai/main.html/_v1/_s2 により次のセグメントを要求することや、新たなバージョンを要求することもできる。このようにコンテンツを分割して扱う際にはコンテンツ名にそのメタデータを付与することが可能である。

■名前解決とデータルーティング NDNにおいて、Subscriber はコンテンツを取得する際はコンテンツ取得要求である INTEREST パケットを発行して、Publisher からの DATA パケットの形式で到着するコンテンツを取得する。INTEREST/DATA パケットは、それぞれ要求/転送されるコンテンツのコンテンツ名を持つ。Fig 2.2 に示すように、すべてのパケットは Content Router (CR) によってホップバイホップ (hop by hop) で転送され、各 CR には 3 つのデータ構造 (Forwarding Information Base (FIB), Pending Interest Table (PIT), Content Store (CS)) がある。FIB は、INTEREST パケットを適切なデータソースに転送するために使用するインターフェイスとコンテンツ名をマッピングする。PIT は、保留中の INTEREST パケットが到着した受信インターフェイス、つまり一致する DATA パケットが転送されてきたときに返送するインターフェースとコンテンツ名をマッピングすることで INTEREST パケットを追跡する。最後に、CS は CR を通過したコンテンツのローカルキャッシュとして機能する。

INTEREST パケットが到着すると、CR はコンテンツ名を抽出し要求されたプレフィックスと一緒に

^{*6} Palo Alto Research Center (PARC) : アメリカ合衆国のカリフォルニア州パロアルトにある研究開発企業

^{*7} NSF FUTURE INTERNET ARCHITECTURE PROJECT (<http://www.nets-fia.net/>)

^{*8} "/"で区切られた部分をセクションと呼ぶ

致する名前を持つ CS のコンテンツを探す。CS でキャッシュが見つかった場合、すぐに DATA パケットとして受信インターフェイスを介して送返され、INTEREST パケットは破棄される。それ以外の場合、CR はこの INTEREST パケットを転送するインターフェースを決定するために、FIB で最長プレフィックス検索を実行する。FIB でエントリが見つかった場合、CR は PIT に INTEREST パケットの受信インターフェイスとコンテンツ名を記録し、FIB が示す CR に INTEREST パケットを転送します。Fig 2.2 では、Subscriber は `/aueb.gr/ai/new.htm` という名前の INTEREST パケットを送信する(矢印 1~3)。PIT にコンテンツ名のエントリが既に含まれている場合、つまりこのコンテンツが既に要求されている場合、CR は受信インターフェイスをこの PIT エントリに追加し、INTEREST パケットを破棄する。

要求されたコンテンツ名に一致するコンテンツが Publisher または CS で見つかった場合、INTEREST パケットは破棄され、コンテンツは DATA パケットとして返送される。この DATA パケットは、PIT で維持されている状態に基づいてホップバイホップ方式で Subscriber に転送される。具体的には、CR は DATA パケットを受信すると、対応するコンテンツを CS に保存し、PIT で最長プレフィックス検索を実行して、DATA パケットに一致するエントリを見つける。PIT エントリに複数のインターフェイスがある場合、DATA パケットが複製され、マルチキャスト配信が実現される。最後に、CR は DATA パケットをこれらのインターフェイスに転送し、PIT からエントリを削除する(矢印 4~6)。PIT に一致するエントリがない場合、CR は DATA パケットを重複データとして破棄する。NDN では、DATA パケットは INTEREST パケットによって PIT に残された経路に従うため、名前解決とデータルーティングは対称である[7]。

■ICN の実用化に向けて ICN における Contents Router (CR) は未だに研究段階にありソフトウェアとして参考実装^{*9}はあるが、ハードウェアとして実装されたものはない。ICN の実用化を行うため、CR のハードウェアによる実装が不可欠である。ハードウェア実装に向けた課題として、TCP/IP における IP アドレスの代わりにコンテンツ名を用いて名前解決とルーティングを行うため CR での処理が複雑であり、各テーブルに必要な記憶容量も増加するという点が挙げられる。この問題を解決するためにコンテンツ名に対してハッシュ化^{*10}を行うことによりルーティングに用いる識別子の圧縮などが研究されている[8][9]。しかし、これらは既存のハッシュアルゴリズム^{*11}を用いているため、ハードウェアで実装するには複雑過ぎる。また、ICN におけるコンテンツ名のハッシュ化という用途では完全に衝突のないハッシュを用いるより、多少の衝突を許容しながらも高速に計算可能なハッシュアルゴリズムが求められる。この多少の衝突を許容するために各テーブルにおける新たなデータ構造による検索手法も求められる。

1.3 本研究の目的

本研究では、上記課題を解決するために新たなデータ構造による検索手法と高速で軽量なハッシュアルゴリズムを提案、検証することである。コンテンツ名はランダムな文字列ではなくある程度自然言語的な規則があるのでそれを用いることで軽量化を図る。

^{*9} Cefore: <https://cefore.net/> NICT により開発された CCNx 準拠の TCP/IP 上で CCN パケットをシミュレートするソフトウェアルータ

^{*10} 本稿ではあるデータを規則に則って処理したときに出力されるものをハッシュ、その規則をハッシュアルゴリズム、またこの処理を行うことをハッシュ化と呼ぶ。

^{*11} MD5, SHA1 など

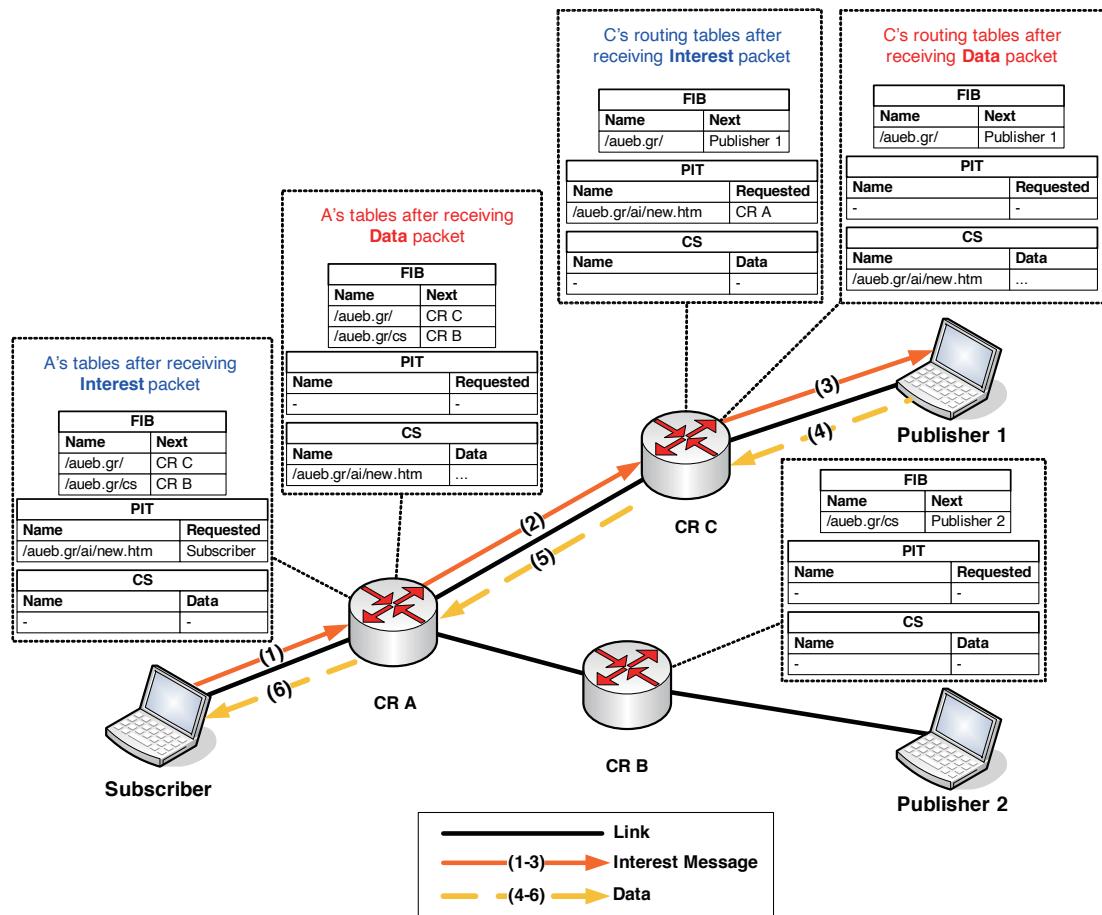


Fig 1.1 The CCN/NDN architecture. CR stands for Content Router, FIB for Forwarding Information Base, PIT for Pending Interest Table, CS for Content Store (Excerpt from [7]).

第2章

方針

2.1 URL のクラシフィケーション

NDN のコンテンツ名は URL に似ているのでまず URL の階層構造について調べる。

Uniform-Resource-Locator(URL) は RFC1738[10] により規格化されており、リソースの位置を特定するために用いられる。HTTP URL の構造を Fig 2.1 に示す。また、Table 2.1 に各変数の説明を示す。

```
<scheme>://<host>:<port>/<path>?<searchpart>
```

Fig 2.1 HTTP URL Structure

Table 2.1 HTTP URL variables description

Variables	Description
<scheme>	http, https などのプロトコル体系を表す。
<host>	ネットワークホストのドメイン名、または IP アドレス。”.”によって区切られるドメインラベルの連続は、各々のドメインラベルが英字あるいは”-”を含んだ文字で開始・終了する。
<port>	接続先のポート番号。デフォルトのポート番号(80,443)以外のポートを指定するときのみコロンで区切って続ける。
<path>	HTTP セレクタでリソースの位置を指定する
<searchpart>	検索パラメータである。これが省略されたときは”?”も省略される

2.2 プログラム

ハッシュアルゴリズムの検証・URL の構造解析を行うためにシミュレーションプログラムを Golang で作成した。

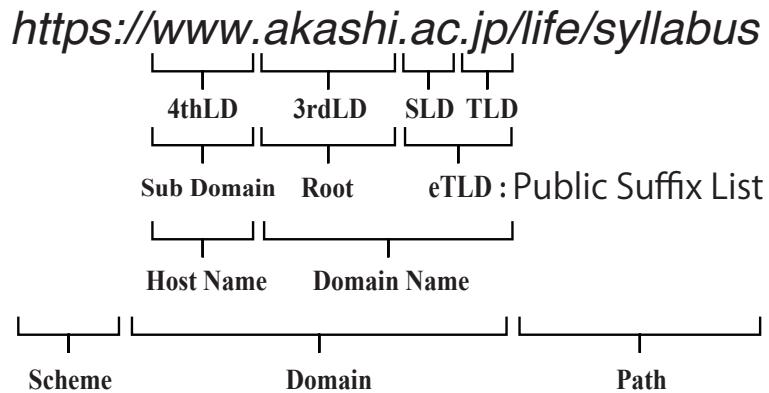


Fig 2.2 The CCN/NDN architecture. CR stands for Content Router, FIB for Forwarding Information Base, PIT for Pending Interest Table, CS for Content Store (Excerpt from [7]).

2.3 データの前処理

シミュレーションに用いるデータとして、The Content Name Collection^{*1}で公開されている情報指向ネットワークのための膨大な URL のデータセットを用いる。そのデータセットの内の一つである urls.txt を使う。urls.txt は Fig 2.3 のように改行で区別されている URL のリストになっている。urls.txt の概要を Table 2.2 に示す。

```

http://www.google.com
http://images.google.com/imgres
http://www.19lou.com
http://www.sfd.com
http://www.baidu.com
http://www.sina.com.cn
http://www.netvibes.com/
http://www.google.com/search
http://images.google.com/
http://wrestlingabrasil.blogspot.com/
  
```

Fig 2.3 Sample 10 in the urls.txt

Table 2.2 Dataset "urls.txt" overview

Dataset	Number of URLs	unique	File size
urls.txt	2,144,314,011	no	121 GB (130,782,049,461 Bytes)

urls.txt の前処理として以下の工程を行う。

^{*1} <http://www.icn-names.net/> にて”The Content Name Collection”というバーゼル大学による情報指向ネットワークのためのデータセットが 2019 年 10 月まで公開されていたが、ドメインの有効期限切れのため現在は全く関係のない中国の会社によりドメインが取得されている。

1. このデータには重複が含まれているので重複を削除する。
2. 各 CR での実際的な URL は 10MB ほどであるという仮定のうえ、ランダムな 10MB ごとのサンプルを抽出する。

2.4 ハッシュアルゴリズム

第3章

衝突数の検証結果

3.0.1 ハッシュアルゴリズム

3.1 URL の分類手法を利用するとき

3.2 ハッシュと URL の分類手法を併用したとき

参考文献

- [1] David D. Clark et al. Barry M. Leiner, Vinton G. Cerf. Brief history of the internet. Internet Society, 1997.
- [2] Cisco. Cisco visual networking index: Forecast and trends, 2017 - 2022. Cisco, 2019.
- [3] Van Jacobson, Diana K. Smetters, James D. Thornton, Michael F. Plass, Nicholas H. Briggs, and Rebecca L. Braynard. Networking named content. In *Proceedings of the 5th International Conference on Emerging Networking Experiments and Technologies*, CoNEXT '09, pp. 1–12, New York, NY, USA, 2009. Association for Computing Machinery.
- [4] 朝枝仁, 松園和久. 情報指向ネットワーク技術におけるプロトタイプ実装と評価手法. コンピュータソフトウェア, Vol. 33, No. 3, pp. 3_3–3_15, 2016.
- [5] NSF Named Data Networking project. [Online]. Available: <http://www.named-data.net/>.
- [6] Content Centric Networking project. [Online]. Available: <http://www.ccnx.org/>.
- [7] G. Xylomenos, C. N. Ververidis, V. A. Siris, N. Fotiou, C. Tsilopoulos, X. Vasilakos, K. V. Katsaros, and G. C. Polyzos. A survey of information-centric networking research. *IEEE Communications Surveys Tutorials*, Vol. 16, No. 2, pp. 1024–1049, Second 2014.
- [8] Lorenzo Saino, Ioannis Psaras, and George Pavlou. Hash-routing schemes for information centric networking. In *Proceedings of the 3rd ACM SIGCOMM workshop on Information-centric networking*, pp. 27–32, 2013.
- [9] 須士小松, 卓也朝香. コンテンツ指向ネットワークにおけるブルームフィルタを用いた経路情報管理方式(ネットワークシステム). 電子情報通信学会技術研究報告 = IEICE technical report : 信学技報, Vol. 113, No. 35, pp. 13–18, may 2013.
- [10] M. McCahill Xerox Corporation. Uniform resource locators (url), dec 1994.